DÉPLOYEZ UN MODÈLE DANS LE CLOUD

KONAN KOFFI

PLAN DE PRÉSENTATION

I/ Problématique et jeu de données

II/ Étapes de la chaîne de traitement

• Preprocessing et réduction de dimensions

III/ Différentes briques d'architecture choisies sur le cloud et leur rôle dans l'architecture Big Data

IV/ Conclusion et recommandation

I PROBLÉMATIQUE ET JEU DE DONNÉES

Start-up de l'AgriTech



Objectifs

> I Reconnaissance de fruit



ORANGE

Riche en vitamine C

- action antioxydante
- favorise l'absorption du fer
- ..

> Il Introduire de l'IA dans la récolte de fruit tout en respectant la biodiversité des fruits





I PROBLÉMATIQUE ET JEU DE DONNÉES

Problématique

• Comment pourrait-on traiter de gros volumes de données (volumétrie extrême)?

Mission

- Mise en place de premières briques de traitement des images
- Développement de scripts adaptés en termes de volume de données et de vélocité dans un environnement Big Data



Jeu de données*


• Un jeu de données avec 90380 images de 131 fruits et légumes



Plus d'I Go de Données




 Une infrastructure de calcul de cluster open-source avec des analyses en mémoire (in-memory)



- Plus rapide que certains systèmes informatiques en cluster (Hadoop)
- ➤ 100 fois plus vite en mémoire et 10 fois plus vite même sur le disque
- ➤ Idéale pour l'analyse de données à grande échelle



Architecture globale Apache Spark



Mise en place de la SparkSession dans le notebook Jupyter



API Python pour Spark

SparkSession: commencer à programmer avec

Spark SQL & DataFrame,
Spark Datasets,
Spark MLlib.




DataFrame

origin h	eight v	vidth nCh	annels m	ode					data
s3a://dmc-in/Trai	798	324	3	16 [FF	FF	FF	FF	FF	F
s3a://dmc-in/Trai	797	325	3	16 [FF	FF	FF	FF	FF	F
s3a://dmc-in/Trai	793	335	3	16 [FF	FF	FF	FF	FF	F
s3a://dmc-in/Trai	796	328	3	16 [FF	FF	FF	FF	FF	F
s3a://dmc-in/Trai	787	339	3	16 [FF	FF	FF	FF	FF	F
only showing top 5 rows	N.								
image: struct (nul origin: strin height: integ width: intege	g (null er (nul	lable = t llable =	true)						

-- nChannels: integer (nullable = true)
-- mode: integer (nullable = true)
-- data: binary (nullable = true)

Conversion des code de couleurs et modification de la taille de nos images à 224 × 224







attendue : **BGRA**




Image bleue après traitement Spark

Transformations

- RGB → BGR
- Échelle réduite




224 × 224





Keras Extraction de features

Transfer Learning via ResNet50 model




- Suppression de la dernière couche du réseau de neurones
- Récupération des poids

Vectorisation des features d'images

- Vecteurs denses
- Nécessaire pour MLlib

Réduction de dimensionnalité PCA (intégré à Spark)



DataFrame avec PCA(features) + Label

pca_features	label
[14.5507688986928	++ cucumber 1
[14.6421758454457	cucumber_1
[14.0862501664891 [15.6812748471574	the second secon
[12.4223389816891	
only showing top 5 ro	++ WS



Stockage de DataFrame

Architecture Big Data AWS

basée sur un serveur EC2 Linux



S

 Stockage de données





- Calculs
 - Déploiement de modèle




MΑ

Control d'accès

S3 (Simple Storage Service)

Évolutivité de stockage d'objets, Disponibilité des données


Sécurité et des performances de pointe






S3, Buckets et Objets

- Fonctions de gestion pour **optimisation**, **organisation** et pour **configuration** de l'accès aux données (des structurées aux non-structurées)
- Répondre à des exigences spécifiques







Création de l'instance EC2 server Linux

Clé privée

Création obligatoire d'une paire de clés publique/privée **SSH**?

Protocole de **connexions** sécurisées entre deux systèmes

Clé publique

Architecture client/server





Clé publique

Échange de clés sécurisées




Systèmes hôte servers AWS EC2 Linux






IAM (Identity and Access Management)

Rappel: Service de gestion des identités et des accès d'AWS






Autorisation d'un accès total aux ressources S3



Tableau de bord de notre instance EC2 et configuration du notebook Jupyter sur AWS




Communication entre Spark et AWS S3

Autorisation d'accès aux fichiers dans S3 à EC2

Complément de dépendances dans le répertoire Spark

Dépendances java « module.jar » :




hadoop-aws-3.3.1.jar

 Intégration de Spark (et autres applications de l'écosystème Hadoop) avec AWS

Le connecteur S3A permet de lire et d'écrire des fichiers stockés dans Amazon S3 grâce avec une URL de préfixe : s3a://

aws-java-sdk-bundle-1.11.901.jar

- Prise en compte du cycle de vie des API,
- Gestion des informations d'identification, les tentatives, l'organisation des données et la sérialisation



IV/ CONCLUSION ET RECOMMANDATION

Tout projet qui consiste à étudier des millions voire des milliards de données doit judicieusement se tourner vers des outils adaptés au Big Data.

> Scripts





Une place de choix dans le calcul distribué accélérant principalement la vitesse d'exécution de traitement sur des bases de données d'une extrême volumétrie.

Les ressourcesBig Data



Recommandation

au traitement de données évolutives

- > Amazon EC2
 - + Auto Scaling

Bon complément à l'équilibrage de charge

Amazon EMR(Elastic Map Reduce)

mise en place automatique d'un cluster Spark qui gère naturellement l'auto scaling en fonction de son paramétrage.

Merci pour votre attention